
PRODUCTO INTEGRADOR DE APRENDIZAJE - MINERÍA DE DATOS

Reporte de Inteligencia de Negocios

Amazon Sales Dataset

Jose Anastacio Hernandez Saldaña

Rodrigo Lopez Escobedo

2049807

18 / Mayo / 26

El dataset: 50,000 órdenes, 14 variables

Fuente: Kaggle. Naturaleza: sintético (generado artificialmente). Distribuciones balanceadas en todas las variables categóricas.

Variables del dataset		
VARIABLE	TIPO	DESCRIPCIÓN
order_id	int	Identificador único de la orden
order_date	datetime	Fecha de la orden (YYYY-MM-DD)
product_id	int	Identificador único del producto
product_category	string	Books, Fashion, Sports, Beauty, Electronics, Home & Kitchen
price	float	Precio original del producto
discount_percent	int	Porcentaje de descuento (0–100)
quantity_sold	int	Unidades vendidas en la orden
customer_region	string	North America, Asia, Europe, Middle East
payment_method	string	UPI, Credit Card, Wallet, Debit Card, Cash on Delivery
rating	float	Calificación del producto (0–5)
review_count	int	Número de reseñas del producto
discounted_price	float	Precio después del descuento
total_revenue	float	discounted_price × quantity_sold

Composición por categóricas

Cada valor aparece prácticamente el mismo número de veces

6 CATEGORÍAS DE PRODUCTO

Books · Fashion · Sports · Beauty · Electronics · Home & Kitchen

4 REGIONES DE CLIENTE

North America · Asia · Europe · Middle East

5 MÉTODOS DE PAGO

UPI · Credit Card · Wallet · Debit Card · Cash on Delivery

El rating y los ingresos


Sin sentido como consumidor, pero en el dataset es contundente

CORRELACIÓN DE PEARSON

-0.0029

Figura 1 — Rating vs. Total Revenue

n = 50,000 · Línea de regresión en naranja



La nube de puntos es **plana**: no hay tendencia.

Un producto con **1 estrella** genera prácticamente los mismos ingresos que uno con **5**.

Agrupando por rating, los ingresos totales son **iguales** en cada nivel.

Precio y cantidad es el 85% de los ingresos



Vender en volume a buenos precios

Tabla 1 — Correlaciones
Coeficiente de Pearson, n = 50,000

PAR DE VARIABLES	R
price ↔ revenue	+0.71
quantity ↔ revenue	+0.59
price ↔ quantity	~0.00
rating ↔ revenue	-0.0029

price y quantity **no se canibalizan** ($r \approx 0$).

Cada una aporta información distinta al modelo.



Ninguna categoría vende más. Ni ninguna región compra más.

Cinco pruebas, cinco veces $p > 0.05$. Los grupos son estadísticamente iguales.




Tabla 2 — 5 pruebas estadísticas
 $\alpha = 0.05$

#	NUMÉRICA	GRUPOS	ANOVA	K-W	SIG.
1	revenue	categoría	>.05	>.05	NO
2	price	categoría	>.05	>.05	NO
3	rating	categoría	>.05	>.05	NO
4	revenue	región	>.05	>.05	NO
5	quantity	región	>.05	>.05	NO

K-Means encuentra clusters reales solo cuando hay correlación.

Con price y revenue: 3 segmentos claros. Con variables no correlacionadas no tiene sentido

K ÓPTIMO (CODO)

3

SILHOUETTE · PRICE + REVENUE

0.4664

SILHOUETTE · RATING + QUANTITY (CONTRAPRUEBA)

0.421

Figura 5 — Método del codo

Inercia (WCSS) vs. K





Figura 6 — Segmentación

Price vs. Total Revenue · 3 clusters



KNN no logra clasificar la categoría: 17% de precisión.

Agregar más variables no ayuda. El dataset no tiene patrones locales que aprender.

ACCURACY MÁXIMO
~17%

Tabla 3 — Experimentos

CV 5-fold · $K \in [1, 20]$ · StandardScaler

#	FEATURES	TARGET	ACCURACY
1	price + qty + discount	category (6)	~0.17
2	+ rating	category (6)	~0.17
3	+ review_count	category (6)	~0.17
4	todas numéricas	good / bad	débil

Lectura


Hay 6 clases balanceadas → **azar = $1/6 = 16.7\%$** .

El modelo está esencialmente **al nivel del azar**.

Más features no producen ganancia: no hay señal.


Figura 7 — Error vs. K

El error nunca baja significativamente



Sin tendencia no hay pronóstico

Dos pruebas independientes que confirman el mismo origen: dataset sintético uniforme.



Conclusion

01 · RATING

-0.0029

El rating no afecta los ingresos. La intuición del consumidor no se sostiene en estos datos.

02 · PRECIO + CANTIDAD

$R^2 = 0.85$

Precio y cantidad, juntos e independientes, explican el 85 % de la variación en los ingresos.

03 · DATASET SINTÉTICO

$p > 0.05$

ANOVA sin diferencias · KNN al 17 % · Forecast plano · Nube uniforme. Misma raíz.
